

质量评测基线与成本可观测

WeKnora • 腾讯犀牛鸟课题三技术报告

刘蔚霖 南开大学 GitHub: Aokiuuz

源码提交: ad3330d549adc2c17d0193d22dcdcecf69a7ab12

系统在 WeKnora 中提供持久化评测工作台、模型逐调用账本、按模型与时间查询的用量面板、持久化嵌入缓存和 Wiki 固定前缀提示词。数据集、模型配置、指标版本和运行源码随实验冻结，逐题结果支持比较及导出。

确定性工程验收中，重建索引的嵌入调用由冷轮 25 次降为热轮 0 次；两轮各完成 20 题和 20 次生成调用。对生产排名融合施加真实召回退化后，门禁报告 recall=0 并以退出码 1 拒绝。

证据层	规模	适用范围
工程验证	Go 9,259 通过 / 33 跳过；前端 921 通过	准确源码下的契约、迁移、缓存、故障恢复和构建
实际模型实验	600 个问题 × 2 个模型；另有 4 组检索实验	固定公开子集的已观察结果
Wiki 配对实验	3 批 × 30 对	供应商缓存令牌、费用与延迟分别统计
八解析引擎	100 份相同文档 × 8	636 成功、160 错误、4 空输出，全部保留分母

成果覆盖固定评测、质量回归、模型统计与两类缓存。前端通过 921 项测试、34 个中英文布局场景和 5 项实际按钮操作；完整后端验收对应 1cc446d，当前三个组件的模板与脚本与该基线一致。实验版本和指标口径见 versions.json 与 EXPERIMENTS.md。

项目仓库: <https://github.com/Aokiuuz/WeKnora>
完整功能贡献: <https://github.com/Tencent/WeKnora/pull/3220>
要求闭合: ACCEPTANCE.md; 复现: REPRODUCE.md。

源要求与验收路径

《WeKnora 开源实战课题》和《WeKnora 腾讯犀牛鸟课题实战流程指引| 2026》定义功能、验收与提交格式。六项必做任务、四项核心验收和八引擎选做分别通过 T1-T6、A1-A4 和 O1 关联实现与证据。

持续集成 CI (Continuous Integration) 运行自动检查；结构化导出采用 JSON (JavaScript Object Notation) 和 CSV (Comma-Separated Values) 。安全散列算法 SHA-256 (Secure Hash Algorithm 256-bit) 标识输入、输出和归档字节。

编号	源要求	实际入口
T1	固定数据集、模型与分块参数，结果入库	实验快照、版本化数据集、租户任务、逐题结果
T2	每轮检索准确性、答案质量、成本与耗时	冻结指标计划、调用账本、工作台和导出
T3	定时 CI 与退化阻断合并	回归和性能 workflow；分支必需检查
T4	每次模型调用记录与模型页展示	modelobs、model_statistics、模型用量面板
T5	相同文本与模型复用嵌入	modelcache、持久存储、共享请求协调
T6	固定提示词在前，可变内容在后	Wiki 提示词组装和配对缓存实验

验收	验证动作	预期
A1 单命令	干净准确提交运行 make evaluation-verify	退出 0；13 项固定指标及服务验证通过
A2 真退化	生产融合路径只保留最差候选	服务召回下限失败，退出 1，指出 recall
A3 模型统计	实际界面切换模型及时间窗口	界面查询数据库，过滤条件与返回一致
A4 两类缓存	嵌入重建与 Wiki 配对比较	25→0 嵌入；三批缓存令牌和费用对照

选做 O1 包含八解析适配器、统一输入清单和失败感知评分。输入是 100 份相同可移植文档格式 PDF (Portable Document Format) 文件，输出包括逐页状态、文本、阅读顺序、表格和公式字符串的机器评分。源要求的名称、摘要及逐项对应见 ACCEPTANCE.md。

评测生命周期与租户隔离

评测以租户、数据版本和实验快照为边界。创建入口冻结数据摘要、模型配置指纹、检索参数、生成预算及指标算法版本。执行器认领持久租约，调用检索和生成，再保存逐题结果。图 1 展示主要数据流。



图 1 实验身份、逐题结果与调用账本的数据流。界面与导出读取持久结果；来源摘要连接运行配置与结果。

心跳维持任务租约；写入和终态发布同时检查租户、持有者、版本与有效期。取消状态先持久化，再中止本地工作；失效持有者不能覆盖新持有者的状态。资源清理核对知识库、文档和租户绑定，并在有界的独立上下文中执行。

状态	编码	含义
pending / running	0 / 1	待执行或租约有效的执行状态
success / failed / timed_out	2 / 3 / 4	完成、失败或超时
interrupted / canceled	5 / 6	失效租约回收后的中断，或持久取消

进程终止后的恢复负责回收失效任务、清理资源并发布中断或取消终态。恢复以资源清理和终态发布为完成条件。超文本传输协议 HTTP（Hypertext Transfer Protocol）故障实验验证取消、重复取消及进程终止后的状态 6 和 5。

指标、来源与回归门禁

指标计划冻结算法键、版本及参数。检索指标包括准确率 Precision、召回率 Recall、平均倒数排名 MRR (Mean Reciprocal Rank)、归一化折损累计增益 NDCG (Normalized Discounted Cumulative Gain) 和平均准确率均值 MAP (Mean Average Precision)。答案指标包括 BLEU、ROUGE、完全匹配 EM (Exact Match) 及词面 F1 (词级准确率与召回率的调和平均)。BLEU 为 Bilingual Evaluation Understudy; ROUGE 为 Recall-Oriented Understudy for Gisting Evaluation。

固定指标	冻结值
generation.bleu.n1	0.577880078307
generation.bleu.n2	0.587072574594
generation.bleu.n4	0.617652476271
generation.exact_match	0.5
generation.rouge.rouge-1	0.4999999975
generation.rouge.rouge-2	0.4999999975
generation.rouge.rouge-l	0.4999999975
retrieval.map	0.75
retrieval.mrr	1
retrieval.ndcg.k10	0.913117328564
retrieval.ndcg.k3	0.913117328564
retrieval.precision	0.5
retrieval.recall	0.75

固定响应门禁使用两题、种子 42 和并发 1，对 13 项数值按冻结容差比较。完整服务门禁使用 20 题、24 段语料和 32 维合成嵌入，检索召回下限为 0.7416666666666666，NDCG@3 下限为 0.5310068874168308。两层覆盖对象不同，分别保留数据和分母。

实际退化探针修改生产排名融合，仅保留最差候选，使 HTTP 门禁返回 recall=0 below frozen minimum，退出码为 1。探针恢复后源码摘要一致；适用函数与阈值在提交版本中保持相同字节。运行记录还拒绝缺失源码身份的服务二进制。

lint 在完整 Git 检出上以合并请求 PR (Pull Request) 的目标提交计算新增诊断，避免托管差异接口的文件数限制。新增缺失导出说明的函数会使检查退出 1，验证记录保留临时负例与恢复结果。

缓存身份与费用可观测

嵌入缓存身份包含租户、模型标识、影响模型行为的配置指纹、请求选项摘要及文本摘要。读取检查向量维度与有限数值。共享执行协调内部再次读取持久缓存，已填充项直接复用，只将剩余文本发送到供应商，避免先前未命中读与另一轮写入交错造成重复调用。

检查	结果	验证口径
完整服务持久复用	冷轮 25 次嵌入，热轮 0 次	两轮各 20 次生成，检索质量一致
并发未命中交错	100 次重复，400 个测试/子测试完成	缓存与调用账本竞态测试另有 34 项通过
异常存储恢复	向量仍返回，告警只含固定类别及数量	存储失败保留独立告警状态
生成输出预算	同时设置两种上游长度字段	冻结实际有效预算，实际出站请求验证为 256

模型调用包装器保存开始和终态、实际令牌用量、供应商缓存字段、应用缓存状态、模型配置摘要和价格版本。金额使用整数微货币单位并区分币种；供应商报告金额、价格估算和缺失值具有不同身份。普通业务请求采用最佳努力记账，严格评测将记账失败传播为失败。

供应商缓存读取令牌比例使用提示词令牌作分母；应用嵌入缓存比例使用查询事件作分母。未知缓存字段保留缺失。流式 Anthropic 响应保留工具分片索引和实际用量；缺少正常结束标记的流保留不完整状态。

共享累计费用

金额单位为美元（United States Dollar，USD）。

项目	数量
累计授权上限	USD 20
已报告费用	USD 0.922374105923
未结算预留	USD 0.728884
费用与预留合计	USD 1.651258105923
账本记录 / 未知费用记录	2964 / 32
当前适配新增付费请求	0

费用表采用共享累计账本口径，已知费用与预留分别统计。三种云解析接口的 300 条逐页费用为未知值，实际云账单合计仍为未知。

精确分位数的规模观测

模型统计按租户、模型和时间从数据库聚合。延迟读取使用行流并保存数值样本，精确分位数按线性插值计算。样本存储与排序的资源使用随行数增长，查询时间窗口上限为 366 天；容量参数包含行数和并发数。图 2 对比同一合成工作负载下的累计内存分配，单位为兆字节 MB（Megabyte，100万字节）。




图 2 相同 SQLite 输入、Go 1.26 和 GOMAXPROCS=2 下的观测。灰色为被比较的行集合读取，绿色为当前行流读取；数值为每请求累计内存分配。

行数 / 并发	行集合耗时	行流耗时	测量单位
1 万 / 1	30.9 ms	27.5 ms	每批一次查询
10 万 / 1	297.6 ms	268.4 ms	每批一次查询
100 万 / 1	3.361 s	2.728 s	每批一次查询
100 万 / 4	6.295 s	4.790 s	整批四次并发查询

数据库准备在测量区间之外。每个点测量一次，检查记录数和精确中位数 499.5；同一测试代码摘要与两份生产文件摘要随证据保存。测量结果适用于所列本机环境、行数及并发条件。

```
GOMAXPROCS=2 GOMEMLIMIT=2GiB go test -tags sqlite_fts5 \  
./internal/application/repository -run '^$' \  
-bench BenchmarkModelStatisticsScale -benchtime=1x -count=1
```

仓库提供可复现的规模基准，按记录数和精确中位数校验结果。行流读取在所列规模下减少累计内存分配，并保持精确分位数口径。

实际问答实验与失败分析

原始上下文读者实验覆盖中文阅读理解数据集 CMRC2018 (Chinese Machine Reading Comprehension 2018)、含无答案问题的 SQuAD2 (Stanford Question Answering Dataset 2.0) 和多跳问答数据集 HotpotQA。每个数据集每模型 200 题，合计 1200 份回答。该实验直接提供原文上下文，评价给定上下文的答案生成质量。

数据集	模型	EM	F1	格式无效
cmrc	DeepSeek V4 Flash	0.685	0.906	1
cmrc	Kimi K2.5	0.725	0.923	1
squad	DeepSeek V4 Flash	0.555	0.628	0
squad	Kimi K2.5	0.500	0.571	0
hotpot	DeepSeek V4 Flash	0.565	0.648	0
hotpot	Kimi K2.5	0.635	0.738	4

多参考答案取最高机器分；格式无效与调用失败记零并保留分母。同一原文中的问题具有相关性，预训练数据重叠未知。样本身份为已观察的公开子集；EM 和 F1 评价答案词面匹配，人工评分记录为空值。

失败对象	DeepSeek	Kimi	分母
HotpotQA 可答误拒	28	20	各 200 道可答题
SQuAD2 无答案误答	57	71	各 100 道无答案题

失败类别由互斥规则重算，定位可答误拒和错误前提接受等现象。源码身份为 86436db4cecf13039b9a41ff8c78ac1fac8fff58，回答与规则结果见 data/reader-scores.json。

完整检索增强生成实验

检索增强生成 RAG (Retrieval-Augmented Generation) 实验包含两个数据集、两个模型，每组 50 题和 500 段语料。CMRC 两模型召回均为 1.00，SQuAD2 均为 0.98，后者在本实验单相关标签下对应 49/50。一次空输出与两次未知费用保留；轮次工作者数量为 1 或 4，耗时不直接用于模型排名。

完整 RAG 实验对应源码 d0535cdfb4784ebc8cee73dccdf35c3489555a90；逐题结果保留运行配置、检索证据和调用账本。

Wiki 固定前缀配对实验

Wiki 生成将共享资料与固定指令置于前部，页面变化内容置于后部。三批各 30 对请求固定供应商路由并交替组别顺序。图 3 展示缓存读取令牌总数除以提示词令牌总数，分母包含每组全部 30 次请求。




图 3 三批固定前缀组均具有更高的供应商缓存读取令牌占比。该指标的分母为令牌，不是请求命中与否的二元计数。

批次	读取令牌平均增加	总费用比	中位耗时比
A	1527.7	0.533	0.966
B	1130.1	0.619	0.979
C	1016.2	0.631	1.178

费用比与耗时比均为固定前缀组除以页面优先组。三批固定前缀费用分别为对照的 53.3%、61.9%、63.1%；第三批中位耗时为对照的 1.178 倍。结果支持固定条件下的缓存和费用收益，延迟变化单独解释。

同批请求共享供应商缓存状态，配对具有相关性。四项字符串检查评价指定词语的覆盖情况。逐对数据见 data/wiki-pairs.json；实验来源与计划摘要见 data/experiment-provenance.json。逐批执行身份按原始记录字段登记。

八解析引擎横向基线

解析基线固定 100 份 PDF（Portable Document Format，可移植文档格式）：80 页 OmniDocBench 和 20 页 olmOCR-bench。82 页没有文字层，18 页保留文字层；参考标注仅进入评分器。八个引擎接收相同输入字节，图 4 显示 800 条结果的状态。




图 4 成功 / 错误 / 空输出的逐引擎分布。每行分母均为 100；接口状态、正文覆盖和内容质量分别统计。CPU 为中央处理器（Central Processing Unit），Cloud 表示云端接口。

按图中顺序，具有正文的页数为 14、17、18、8、98、95、84、99，分母均为 100。olmOCR 官方断言通过数为 32、18、36、16、102、104、82、102，分母均为 125。

Paddle CPU 批次执行及五步后处理为 complete，100 条结果均已归档，其中 84 成功、15 错误、1 空输出。100 份 PDF、800 条输入输出摘要及父清单与分片成员均通过一致性核验。

执行二进制 SHA-256 为 8ab644eee861c75b4351c603b5f0b5c268725cb020b333a1b50f4de87b37cd40，归档源码为 a39b8da71db08ff1bf6120f00966e8b1d0a7a96。当前工具构建、输入完整性与离线评分验证通过；逐页结果绑定上述执行身份。

解析质量与上游兼容性

OmniDocBench 评分副本统一删除图片引用、替代文字和路径，原始输出保持完整。文字和阅读顺序采用编辑距离；表格采用 TEDS（Tree Edit Distance based Similarity，树编辑距离相似度）。评分表采用上述统一预处理后的输入。

引擎	文字距离 /78	表格 TEDS /17	顺序距离 /79	公式字符串 /9
Builtin	1.0000	0.00%	1.0000	1.0000
Markdown	1.0000	0.00%	1.0000	1.0000
OpenDataLoader	1.0000	0.00%	1.0000	1.0000
WeKnora Cloud	1.0000	0.00%	1.0000	1.0000
MinerU CPU	0.0818	85.71%	0.1196	0.2547
MinerU Cloud	0.1177	85.71%	0.1560	0.2547
PaddleOCR-VL CPU	0.1527	65.12%	0.2019	0.2021
PaddleOCR-VL Cloud	0.0366	79.02%	0.0850	0.1874

解析结果提供文本、表格、阅读顺序和公式字符串四类机器指标，以及 olmOCR 逐项断言。文字、顺序和公式字符串距离越低越好，TEDS 越高越好；各列保留自己的有效标注分母。完整评分状态与来源清单见 EXPERIMENTS.md。

上游接口与数据库兼容性

集成基础为 Tencent/WeKnora main 的 462999ec3f5c1467ef0ccf5cf8c422393f40a0e6。HTTP 请求与服务器发送事件 SSE（Server-Sent Events）共享上游认证刷新协调器，各调用者保留自己的取消信号。Anthropic 工具流索引、完成预算和缓存字段保持当前协议。模型设置使用上游图标包，新增界面字符串覆盖五种语言。

SQLite 基础迁移为 14，PostgreSQL 基础迁移为 93，课题迁移为独立 16。实际升级探针验证租户、模型、数据集、语料、问题和相关标签的保留；重复迁移检查幂等。部署流程包括数据库备份、迁移和目标版本验证。

解析工具仅通过显式配置文件或标准输入接收凭据。构建验证嵌套分词字典和完整来源提交，离线验证无需解析服务或云账号。可选 PDF 完整性验证与无数据下载的单元检查分别提供命令。

独立验证与界面证据

工程证据将测试、运行二进制和源码分开记录。完整 Go 套件为 9,259 通过、33 跳过、零失败；数据库迁移矩阵另外完成 64 项通过，缓存记账竞态检查 34 项通过。前端 921 项、类型检查和生产构建通过。每项适用版本及文件等价判断见 versions.json 和 EXPERIMENTS.md。

图 5 使用真实本地前后端和合成供应商展示实验详情。界面检查覆盖持久运行、逐题结果、导出、比较及模型时间过滤；中英文另有 34 个布局场景，窄窗口实际完成 5 次导出及比较操作。




图 5 工作台工程夹具示例。界面采用合成供应商和合成价格，展示逐题结果及账本对账。

浏览器后端为 d1fedd6，前端为 c7b47a13 并与当前集成前端字节一致。完整后端验收绑定 1cc446d；三个组件仅有样式变化，模板与脚本相同。Apple M4 平台证据对应 1776aa442a491f1657196ca21da914bab197b17c；当前适配的工程验证环境为 Linux 与 CI。

成果验收与复现入口

课题成果包括固定配置的持久评测、检索与答案指标、模型调用账本、模型及时间统计、两类缓存和回归门禁。六项必做任务、四项核心验收与八解析引擎基线的对应关系见 ACCEPTANCE.md。

在干净克隆中签出 versions.json 的完整 code_commit，安装 Go 1.26、C/C++ 工具链、Python 3.11+ 和 GNU Make，然后运行：

```
make evaluation-verify
```

预期退出码为 0，verification-summary.json 的 status 为 passed，paid_provider_requests 为 0。该命令建立合成供应商和隔离数据，执行固定指标、公开数据、冷热嵌入缓存、任务取消与租约恢复、费用字段、离线解析及源码身份检查。

验收内容	结果与复现观察
固定流程与质量指标	配置和数据版本冻结；13项指标按冻结值比较
退化阻断	生产检索召回退化至0，门禁退出1并指出recall
模型统计与交互	数据库模型及时间筛选；921项前端测试、34布局场景和5项按钮操作
缓存对照	完整服务嵌入调用25→0；三批Wiki费用、缓存令牌和耗时配对
八引擎解析	同批100份PDF、800条状态及文字/表格/顺序/公式字符串评分

完整后端运行对应 1cc446d；当前提交的三个前端组件模板与脚本与该基线一致。真实模型、解析和设备实验采用各自执行身份，版本映射见 versions.json；测量定义与统计分母见 EXPERIMENTS.md。

附件内容	阅读用途
TECHNICAL-REPORT.pdf	系统架构、实现机制、实验图表和结果
README.md / ACCEPTANCE.md	成果概览与源要求逐项对应
REPRODUCE.md	环境、单命令复现和界面查看步骤
EXPERIMENTS.md / data/	样本、指标、费用、执行版本和实验数据
versions.json / checksums.sha256	准确代码身份与成果附件完整性

代码仓库：<https://github.com/Aokiuuz/WeKnora>；完整提交：ad3330d549adc2c17d0193d22dcdcecf69a7ab12